



基于 Agent 的数据市场机制模拟与改进

A Marketplace for Data: An Algorithmic Solution

杨馨懿 郑伊霞 周首航

2026 年 7 月 17 日




目录

- 1 背景与机制设计
- 2 我们的方法
- 3 Agent 设计
- 4 模拟实验及结果
- 5 后续计划
- 6 参考文献



总览



ML 训练数据为什么需要一个专门的交易市场

ML 训练数据作为商品的四个独特挑战 (Agarwal et al., 2019)

- ① **可无限复制**：零边际成本 → 稀缺性定价模型直接失效
- ② **价值是组合性的**：一个数据集的价值取决于买方已有哪些其他数据 → 无法独立定价
- ③ **买方无法为单个数据集报价**：买方没有对特定数据集的先验价值判断
- ④ **价值事前不可验证**：不先跑一遍 ML 任务，谁也不知道数据有没有用

关键

买方真正知道的不是“这个数据集值多少钱”，而是“**预测精度提升 1% 对我来说值多少钱**”。

因此市场的交易单位不应是“数据集”，而应是**预测精度的边际提升**。

论文提出的机制

三方参与者

- **平台**：中心化定价，运行 ML 模型，结算分成
- **买家**：提交预测任务 Y_n 和报价 b_n
- **卖家**：提供数据特征 X_j ，被动接受分成

单轮交易

- ① 买家提交预测任务 Y_n
- ② 买家报价 b_n (“精度提升 1% 付 $\$X$ ”)
- ③ AF 分配数据: $b_n \geq p_n$ 给完整数据，否则加噪声
- ④ 平台训练 ML 模型，计算精度增益 $G(Y_n, \hat{Y}_n)$
- ⑤ RF (Myerson) 计算支付额：**诚实报价占优**
- ⑥ PD (Shapley) 分配收入给卖家：**复制者受罚**
- ⑦ PF (MWU) 更新下一轮价格：**无遗憾定价**

买方不接触原始数据，只拿到模型预测结果

Agarwal, Dahleh, and Sarkar. *A Marketplace for Data: An Algorithmic Solution*. EC '19, 2019.

四大机制及其设计理由

机制	应对的挑战	设计逻辑
Allocation Function (数据分配)	事前不可验证	买方不接触原始数据：平台统一训练模型输出预测，避免数据泄露
Myerson Revenue Function (支付)	策略性谎报	Myerson 支付函数数学上保证 $b_n = \mu_n$ 是占优策略：诚实报价收益最高
Price Update / MWU (定价)	最优价格未知	MWU 在候选价格网格上实现 no-regret：价格自动收敛至最优
Payment Division / Shapley (分配)	可复制 + 组合价值	Shapley 值衡量边际贡献；余弦相似度指数惩罚复制数据

机制仿真：理论结果复现



基于 AF / RF / PF / PD 机制实现，验证诚实报价占优、MWU 价格收敛、复制惩罚三项理论性质

该机制的局限性

局限

- ① **买家是短视的**：只优化单轮效用，不考虑多轮策略
- ② **平台集中定价**：卖家不能自主定价，只能被动接受 Shapley 分成
- ③ **基于严格的私有估值假设**：忽视了数据的竞争外部性（买家效用往往受对手是否获取数据的影响）

论文假定买家为理性、短视的私有估值者，诚实报价仅作为其在单阶段博弈下的占优策略

用 LLM Agent 模拟真实市场参与者

核心思路

保持论文的**市场机制完全不变**，把规则化的买卖双方替换为 **LLM Agent**，观察行为偏差：

- 买家 Agent 面对价格决定报价策略
- 平台 Agent 根据市场反馈调整定价
- 对比理论最优 vs. LLM Agent 的行为差异

核心方法：四模式对比实验 (all_rule / seller_agent / buyer_agent / both_agent)
→ 测量 Utility Gap → 定位机制偏差 → 提出改进



核心研究问题

① LLM Agent 的诚实性

- 面对 Myerson 支付规则, LLM Agent 是否会自发学会诚实报价?
- 诚实报价 vs. 策略性低报: Agent 选哪个? 为什么?



核心研究问题

① LLM Agent 的诚实性

- 面对 Myerson 支付规则, LLM Agent 是否会自发学会诚实报价?
- 诚实报价 vs. 策略性低报: Agent 选哪个? 为什么?

② 多轮博弈中的合谋行为

- 多个买家 Agent 在反复交易中, 是否会集体压低报价?
- MWU 定价机制能否抵御这种隐性合谋导致的价格下行?



核心研究问题

① LLM Agent 的诚实性

- 面对 Myerson 支付规则, LLM Agent 是否会自发学会诚实报价?
- 诚实报价 vs. 策略性低报: Agent 选哪个? 为什么?

② 多轮博弈中的合谋行为

- 多个买家 Agent 在反复交易中, 是否会集体压低报价?
- MWU 定价机制能否抵御这种隐性合谋导致的价格下行?

③ 机制的鲁棒性

- 买卖双方都是 LLM Agent 博弈时, MWU 价格还会收敛吗?
- Shapley 惩罚还能有效阻止复制行为吗?

核心研究问题

① LLM Agent 的诚实性

- 面对 Myerson 支付规则, LLM Agent 是否会自发学会诚实报价?
- 诚实报价 vs. 策略性低报: Agent 选哪个? 为什么?

② 多轮博弈中的合谋行为

- 多个买家 Agent 在反复交易中, 是否会集体压低报价?
- MWU 定价机制能否抵御这种隐性合谋导致的价格下行?

③ 机制的鲁棒性

- 买卖双方都是 LLM Agent 博弈时, MWU 价格还会收敛吗?
- Shapley 惩罚还能有效阻止复制行为吗?

④ 改进方向

- 基于 Agent 的行为偏差, 解释机制为什么有问题
- 探索更贴近现实的合理市场机制设计

Agent 层总体架构



JSON 动作解析器：从自然语言到可执行动作

解析目标

LLM 输出必须最终归一化为环境可执行的动作字典：平台 {" 价格": p}, 买家 {" 报价": b}.

支持的常见输出形态

- 纯 JSON: {" 报价": 0.8}
- Markdown JSON 代码块
- 先解释、后给 JSON
- 嵌套字段: {"action": {"bid": 0.7}}
- 英文字段别名: price, bid

动作校验与统计

- 平台价格裁剪到候选区间
- 买家报价裁剪为非负数
- 统计解析失败、fallback、越界动作
- 保存 reasoning 供后续行为分析

Prompt 设计：角色感知 + 机制引导 + 短期记忆

System Prompt 结构

- ① **角色目标**：平台最大化收益；买家最大化自身效用
- ② **信息边界**：平台不知道买家估值；买家不知道他人信息
- ③ **机制说明**：AF 数据质量、RF 支付、PF/MWU 动态定价
- ④ **实验 profile**：战略型、诚实型、福利型等
- ⑤ **JSON schema**：强制输出可解析动作

User Prompt 每轮注入

- 当前角色与 prompt profile
- 当前观察 obs
- 最近 K 轮记忆
- 内部三步判断：趋势识别、效用影响、数字动作

输出格式

`{"reasoning": "一句话理由", "报价": 0.8}` 或 `{"reasoning": "一句话理由", "价格": 1.0}`

Prompt 示例一：平台定价 Agent

System Prompt: revenue_max

你是数据市场的平台定价 Agent。你只观察候选价格、MWU 推荐价格、卖家数量和最近交易历史；你不知道任何买家的私有估值。你的目标是在多轮交易中提高平台收入，同时避免价格过高导致交易失败。请基于历史反馈选择本轮价格。

User Prompt: 每轮注入

当前轮次、总轮次、候选价格、MWU 推荐价格、最近成交价/报价/平台收益。请先判断最近价格是否偏高或偏低，再从候选价格中选择一个价格，并输出 JSON：
{ "reasoning": "...", "价格": 1.0 }。

为什么这样设计？

平台 prompt 刻意限制信息集，不让它读取买家真实估值；这样可以检验在与论文相同的不完全信息设定下，LLM 是否会偏离 MWU 推荐价、主动试探支付意愿，或因短期收益目标造成价格震荡。

Prompt 示例二：买家 Agent 的三类报价策略

Profile	Prompt 片段	设计目的	验证问题
truthful	你的目标是最大化单轮效用; Myerson 支付规则下, 诚实报价 $b = \mu$ 是占优策略.	理论基线	LLM 能否按机制理论诚实报价?
strategic	除本轮效用外, 也考虑你的报价是否会影响未来价格路径; 不要编造不可见信息.	多轮策略	LLM 会不会为压低未来价格而低报?
shade	如果当前价格低于估值, 可以考虑适度低报以节省支付, 但要权衡拿不到高质量数据的风险.	低报压力测试	Myerson+MWU 能否抵御策略性低报?

统一输出

`{"reasoning": "一句话说明诚实/低报/高报原因", "报价": 0.8}`; 保留 reasoning 是为了把数值偏离和 Agent 的主观解释对应起来.

Prompt 示例三：竞争外部性与风险偏好

竞争型买家：competitive

你与另一个买家在下游市场竞争。如果对手获得高质量预测而你未获得，你的商业收益会下降；如果双方都获得数据，预测优势会被部分抵消。请在当前价格、你的估值、对手可能购买的风险之间选择报价。

验证问题

私有估值假设被打破后，买家估值是否会随对手行为动态变化？诚实报价结论是否仍然稳定？

风险规避买家：risk_averse

你的预算有限，负效用会带来额外风险成本。若价格接近估值，请偏向保守报价；若数据质量提升能显著降低业务风险，可以接受略高报价。输出时说明你主要规避的是支付风险还是质量风险。

验证问题

当参与者不是风险中性时，原机制的收益、效率和成交率是否出现系统性变化？

Prompt 设计动机与可验证问题

设计元素	为什么这样设计	能验证什么问题
角色目标	平台、买家优化目标不同，避免所有 Agent 说出同一种“理性”答案	平台收益最大化与买家效用最大化是否会产生机制冲突
信息边界	明确“不可见估值/他人历史”，对齐论文的不完全信息假设	LLM 是否会在信息受限下仍然推断、臆测或策略性行动
机制说明	告诉 Agent AF/RF/PF/PD 规则，但不直接给最优动作	机制知识是否足以诱导诚实报价或稳定定价
Profile 切换	在同一市场环境下只改变 prompt 偏好	行为偏差来自市场机制，还是来自 Agent 偏好设定
JSON+reasoning	动作可执行，理由可分析	数值异常、fallback、低报/高报能否被解释和统计

Prompt Profiles: 用于行为对照的 Agent 类型

Profile	角色	行为假设
truthful	买家	强调诚实报价 $b = \mu$, 作为理论基线
strategic	买家/平台	允许考虑当前动作对未来价格路径的影响
shade	买家	允许适度低报, 观察 MWU 是否被压价
revenue_max	平台	更强调平台收入和平台效用
fairness_aware	平台	同时关注买家效用和卖家参与激励
welfare/risk_averse	双方	分别强调社会福利或规避负效用风险

中期实验用途

通过固定市场环境、切换 prompt profile, 比较不同 Agent 行为对平台收益、买家效用、卖家收益和动作合法性的影响。

实验流程

模块定位

负责把市场机制环境与外部 Agent 接口组织成可重复运行的多轮实验。

交易轮数由买家序列长度决定：

$$\text{total_rounds} = \text{len}(\text{buyers})$$

一个 episode 表示一段连续交易过程：

- 卖家数据池在实验开始前固定；
- 买家按照预设序列依次进入市场；
- 每一轮中，平台先定价，当前买家再报价；
- 底层 AF/RF/PD/PF 完成结算与价格状态更新；
- 实验系统记录该轮结果并进入下一轮。

四种实验模式

为比较规则机制与 Agent 决策的影响，实验设计四种模式。

模式	平台/卖方定价侧	买家侧	实验目的
all_rule	MWU 规则	诚实报价规则	作为规则基准组
seller_agent	Agent	诚实报价规则	测试平台 Agent 定价影响
buyer_agent	MWU 规则	Agent	测试买家 Agent 报价影响
both_agent	Agent	Agent	测试双边 Agent 交互效果

信息控制

实验提供统一接口：

`agent.act(obs) → action`

观测信息按角色构造：

- 平台侧可见当前轮次、总轮次、候选价格、卖家数量、最近历史；
- 买家侧可见当前轮次、总轮次、自身估值 μ 、当前价格、自身历史；

当前可被 Agent 接管的两个决策点：

- 平台侧定价：{" 价格": p}
- 买家侧报价：{" 报价": b}

实验记录与模块输出

每次外部 Agent 决策都会记录一条 step 日志：

`{role, observation, action, reward, reasoning}`

episode 结束后输出 `EpisodeRunResult`：

- `steps`：逐轮日志，包含 `raw_output`、`reasoning`、`fallback_used`；
- `summary`：平台总效用、买家平均效用、卖家效用等指标；
- `action_stats`：fallback 次数、非法动作次数、缺少 reasoning 次数；
- 自动保存 `baseline_results.json`、`summary_table.csv` 和 `step_table.csv`。

分析目标

核心问题

Agent 接入后，市场结果相对规则基准组发生了怎样的变化？

数据分析主要比较：

- 不同模式下的平台总效用；
- 不同模式下的买家平均效用；
- Agent 是否改变价格、报价、数据增益和平台收入的动态轨迹。

基准组与指标定义

以下分析以 `all_rule` 作为基准组：

$$\text{all_rule} = \text{MWU 定价} + \text{买家诚实报价}$$

Utility Gap 定义为：

$$\text{Utility Gap} = \text{规则基准组效用} - \text{当前模式效用}$$

Pass@epsilon 用于判断某个模式是否足够接近规则基准组：

$$|\text{platform_gap}| \leq \epsilon, \quad |\text{buyer_average_gap}| \leq \epsilon$$

后续计划

① Prompt 与模型消融 + 参数敏感性

- 对比不同的 prompt (balanced / strategic / truthful 等) 对 Agent 报价行为的影响
- 更换模型, 观察不同 LLM 的决策差异
- 扫描关键参数, 评估机制对参数漂移的鲁棒性

② 多轮博弈与合谋行为

- 同一买家 ID 多轮反复交易, 观察 Agent 是否会学会集体压低报价
- 检验 MWU 定价在策略性 Agent 持续博弈下是否仍然收敛

③ 机制改进

- 基于实验发现 (LLM 平台 0.8 优于 MWU 1.05–1.15), 探索用 LLM agent 替代 MWU 定价的可行性.....

参考文献 I

- [1] Anish Agarwal, Munther Dahleh, and Tuhin Sarkar.
A Marketplace for Data: An Algorithmic Solution.
In *Proceedings of the 2019 ACM Conference on Economics and Computation (EC '19)*, 2019.
- [2] Pangjing Wu, Peter Q. Chen, Xiaodong Li, Wenqi Fan, and Li Qing.
Datamart-Agent: LLM-Driven Game-Theoretic Agent for Data Marketplace Modeling.
In *Findings of the Association for Computational Linguistics: ACL 2026*, pages 32509–32531, 2026.
- [3] Nian Li, Chen Gao, Mingyu Li, Yong Li, and Qingmin Liao.
EconAgent: Large Language Model-Empowered Agents for Simulating Macroeconomic Activities.
In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL 2024)*, pages 15523–15536, 2024.
- [4] Chong Zhang, Xinyi Liu, Zhongmou Zhang, Mingyu Jin, Lingyao Li, Zhenting Wang, Wenyue Hua, Dong Shu, Suiyuan Zhu, Xiaobo Jin, Sujian Li, Mengnan Du, and Yongfeng Zhang.
When AI Meets Finance (StockAgent): Large Language Model-based Stock Trading in Simulated Real-world Environments.
arXiv preprint arXiv:2407.18957, 2026.

参考文献 II

- [5] Xianyang Liu, Shangding Gu, and Dawn Song.
AgenticPay: A Multi-Agent LLM Negotiation System for Buyer–Seller Transactions.
arXiv preprint arXiv:2602.06008, 2026.
- [6] Roger B. Myerson.
Optimal Auction Design.
Mathematics of Operations Research, 6(1):58–73, 1981.
- [7] Lloyd S. Shapley.
A Value for n-Person Games.
In *Contributions to the Theory of Games II*, pages 307–317, 1953.



谢谢!

